Clube do Código 22

Previsão da Taxa de Câmbio

Vítor Wilher
Mestre em Economia
analisemacro.com.br

Pacotes e Scripts Externos

```r
library(forecast)
library(ggplot2)
library(BMR)
library(stargazer)
library(urca)
library(rbcb)
library(quantmod)
library(xts)
library(dynlm)
```

1 Coleta, tratamento e visualização dos dados

Os dados que utilizaremos nesse exercício serão coletados em diferentes fontes. O *Credit Default Swap de 5 anos* vem do arquivo *cds5y.csv*, disponível na área restrita, enquanto a taxa de câmbio R$/US$ e a taxa Selic vem do Banco Central, coletadas a partir do pacote `rbcb`.[1] Por fim, os *FED Funds*, a taxa básica de juros norte-americana, será coletada com o pacote `quantmod`. O código abaixo faz essa coleta de dados.

```
### Importar e tratar dados
cds5y <- read.table('cds5y.csv', header = T, sep=';', dec=',')
cds5y$date <- as.Date(cds5y$date, format='%d/%m/%Y')
cds5y <- xts(cds5y$cds5y, order.by = cds5y$date)

selic <- get_series(1178)
colnames(selic) <- c('date', 'selic')
selic$date <- as.Date(selic$date, format='%d/%m/%Y')
selic <- xts(selic$selic, order.by = selic$date)

cambio <- get_series(10813)
colnames(cambio) <- c('date', 'cambio')
cambio$date <- as.Date(cambio$date, format='%d/%m/%Y')
cambio <- xts(cambio$cambio, order.by = cambio$date)

fed <- getSymbols('EFFR', src='FRED')
fed <- EFFR

### Juntar dados no mesmo objeto
data <- cbind(cambio, selic, fed, cds5y)
```

[1] Maiores informações sobre o pacote ver em https://github.com/wilsonfreitas/rbcb. É possível que no uso das funções desse pacote ocorra o erro *Request error, status code = 500*. Isso é um erro de conexão com os servidores do Banco Central. Basta tentar novamente. Caso não consiga de jeito nenhum, utilize os arquivos *cambio.csv* e *selic.csv*, disponíveis juntamente com o exercício.

```
data <- data[complete.cases(data),]
colnames(data) <- c('cambio', 'selic', 'fed', 'cds5y')
```

Observe que não apenas coletamos os dados, como já o tratados utilizando o pacote xts. Como se trata de *dados irregulares*, é preciso ordená-los de acordo com um vetor de datas, utilizando para isso a função `xts` do pacote de mesmo nome.[2] Na sequência, colocamos todos os dados em um mesmo objeto. Vale observar que os dados são irregulares, com frequência diária. E por fim, criamos uma variável chamada de juros, que é a diferença entre a taxa básica no Brasil e nos Estados Unidos.

Para que possamos melhor trabalhar com esses dados, nós vamos *mensalizá-los*, utilizando para isso a função *apply.monthly* também do pacote xts. Feito isso, podemos olhar os gráficos das séries. O código abaixo faz isso.

```
## Mensalizar os dados e transformá-los em séries temporais
data1 <- apply.monthly(data, FUN=mean)
data1 <- ts(data1, start=c(2001,10), freq=12)
## Gráfico com o pacote BMR
dates <- seq(as.Date('2001-10-01'), as.Date('2017-01-01'), by='1 month')
gtsplot(data1, dates=dates)
```

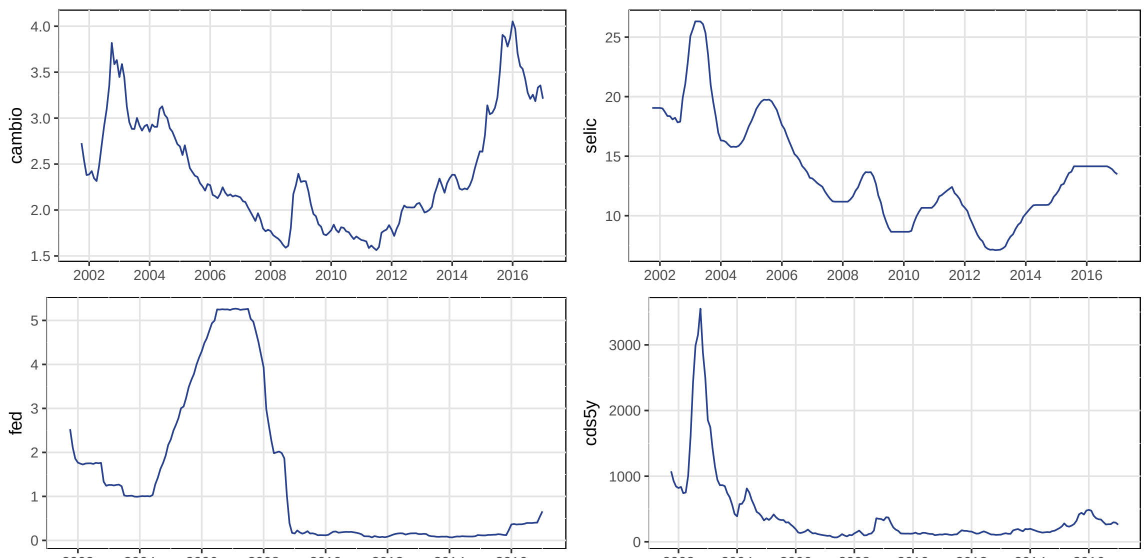

O apêndice A mostra o resultado do Teste ADF Sequencial, aplicado conforme Pfaff (2008). Observa-

[2]Ver a seção sobre importação de dados do nosso Curso de Introdução ao R.

se que a taxa de câmbio e a taxaa de juros norte-americana são passeios aleatórios, enquanto o CDS e o e a taxa Selic são processos estacionários, conforme o protocolo adotado.[3] Levaremos essa informação em consideração no momento da nossa modelagem.

2 Taxa de Câmbio e passeios aleatórios

Observe o leitor que a taxa de câmbio é um *passeio aleatório*. Para entender melhor esse tipo de processo, suponha que uma série y_t possa ser modelada como

$$y_t = y_{t-1} + \varepsilon_t \tag{1}$$

Onde ε_t segue um ruído branco. Substituindo $y_{t-1} = y_{t-2} + \varepsilon_{t-1}$ na equação acima e depois substituindo por y_{t-2}, y_{t-3} e assim por diante, temos:

$$y_t = \sum_{t=1}^{n} \varepsilon_t \tag{2}$$

No R, podemos gerar um passeio aleatório com o código abaixo.

```
x <- w <- rnorm(1000)
for (t in 2:1000) x[t] <- x[t - 1] + w[t]
plot(x, type = "l")
```

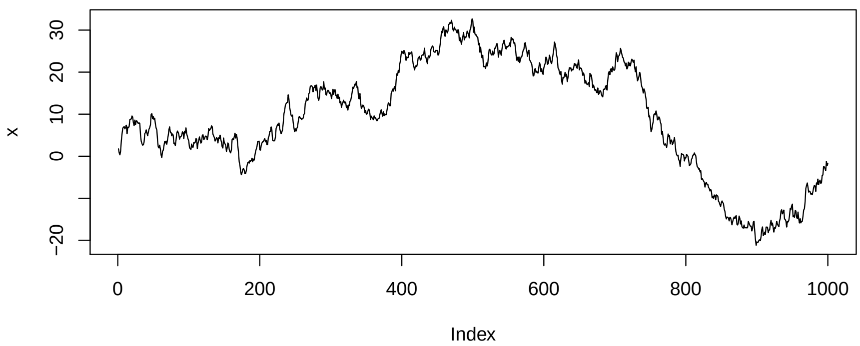

Figura 1: Exemplo de um passeio aleatório.

[3]Há evidências de que, ademais, a taxa Selic seja tendência-estacionária.

Em outras palavras, sendo um passeio aleatório a soma de *choques passados*, é difícil gerar uma previsão razoável sobre o seu comportamento. Ademais, à medida que expectativas e projeções sobre o comportamento da taxa interferem no seu valor futuro, há uma dificuldade ainda maior em gerar previsões acuradas sobre o comportamento da série. Desse modo, talvez a melhor previsão para o câmbio hoje seja o câmbio de ontem, o que pode ser gerado no R como abaixo.

```
rw <- Arima(data1[,1], order=c(0,1,0))
autoplot(fitted(rw))+
  geom_line(colour='darkblue', size=.8)+
  geom_line(aes(,data1[,1]), color='red', size=.8)
```

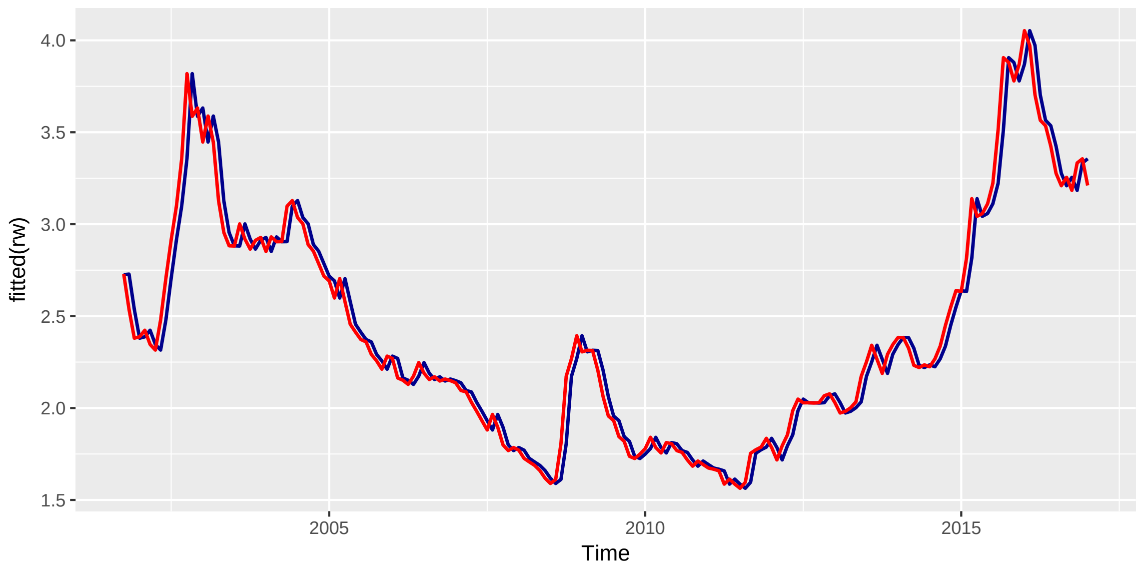

Figura 2: Taxa de Câmbio modelada como passeio aleatório

As previsões geradas por um modelo assim serão naturalmente baseadas na última observação, o que, convenhamos, não seria nada relevante, não é mesmo? Por isso, devemos avançar no nosso entendimento sobre a trajetória futura do câmbio.

3 A paridade descoberta da taxa de juros

De forma a compreender a trajetória da taxa de câmbio, é comum se basear em alguma teoria de paridade. Duas delas se destacam. A primeira, chamada de Paridade de Poder de Compra (PPC), busca verificar a determinação da taxa de câmbio no longo prazo. A segunda, a Paridade da Taxa de

Juros (PTJ) busca estabelecer uma condição de arbitragem, sobre o qual os movimentos do câmbio se baseiam na diferença entre os juros domésticos e internacionais, levando em consideração ainda um prêmio de risco. Em outros palavras,

$$E_t \epsilon_{t+1} - \epsilon_t = i_t - i_t^F - x_t \tag{3}$$

Onde ϵ_t é a taxa de câmbio, i_t é o juro doméstico, i_t^F é o juro internacional e x_t é o prêmio de risco. Podemos, ademais, tomar a primeira diferença e assumir que as mudanças nas expectativas sobre o câmbio seguem um ruído branco. Assim, teremos que

$$\Delta \epsilon_t = \Delta i_t^F + \Delta x_t - \Delta i_t + \eta_t \tag{4}$$

Dessa forma, mudanças na taxa de câmbio são dadas por mudanças nos juros domésticos, nos juros internacionais e no prêmio de risco.[4]

4 Modelagem e Previsão

Para estimar a equação 4, vamos diferenciar os regressores, mantendo a taxa de câmbio em nível, para poder utilizar a função Arima acima. Isso será particularmente importante para gerar previsões em nível na sequência.

```
xreg <- diff(data1[,2:4])
cambio <- ts(data1[-1,1], start=c(2001,11), freq=12)
modelo <- Arima(cambio, order=c(0,1,0),
                xreg=xreg)
```

Uma vez estimado o modelo, podemos agora proceder a geração de cenários para as variáveis exógenas.[5]

```
h <- 11
newreg <- matrix(NA, ncol=3, nrow=h)
```

[4]Ver Bogdanski et al. (2000).

[5]Estamos considerando aqui, claro, cenários puramente estatísticos, o que terá influência decisiva sobre as previsões de taxa de câmbio.

```
colnames(newreg) <- colnames(data1[,2:4])

for(i in 1:3){

  newreg[,i] <- forecast::forecast(auto.arima(xreg[,i], max.p=5, max.q=5,
                                               seasonal=F), h=h, level=40)$mean

}

newreg <- ts(newreg, start=c(2017,02), freq=12)
```

Com os cenários definidos, podemos gerar nossas previsões conforme o código abaixo.

```
cambiof <- forecast(modelo, xreg=newreg, level=c(50,75,95))
```

e abaixo o gráfico com as previsões.

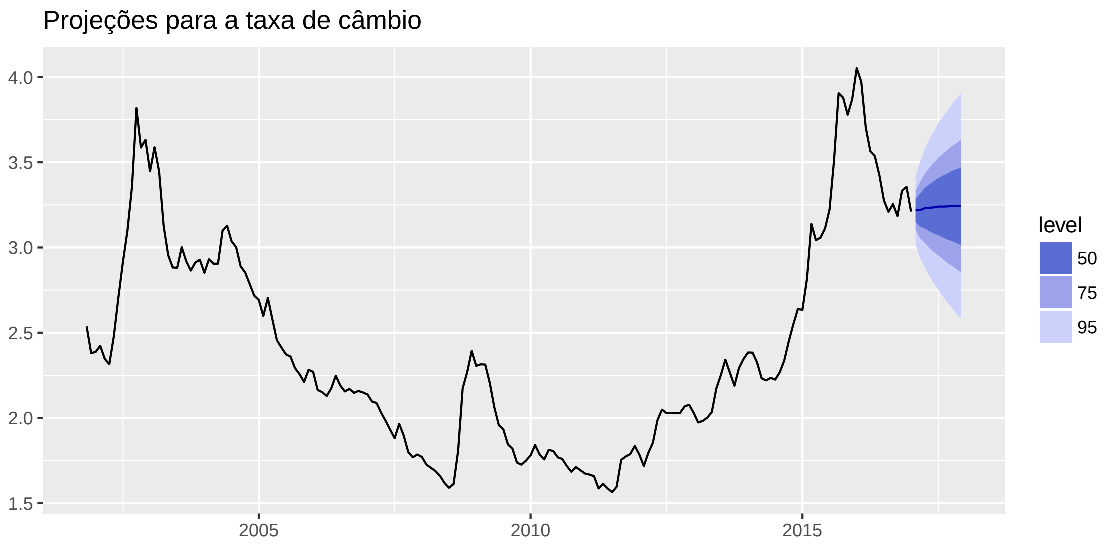

Figura 3: Projeções para a taxa de câmbio

5 Discussões Finais

Gerar previsões para passeios aleatórios é certamente um dos grandes desafios da macroeconometria. Com a taxa de câmbio há ainda um problema adicional, derivado do fato de que as expectativas e projeções acabam por afetar a trajetória futura da variável. Isso dito, procuramos nesse exercício salientar questões operacionais sobre como gerar previsões do câmbio utilizando regressores com base na Paridade Descoberta da Taxa de Juros (PTJ).

Os cenários foram baseados em experimento puramente estatístico, o que constrange os resultados encontrados. De forma a tornar o exercício mais real, o leitor pode considerar trajetórias alternativas para as variáveis exógenas ou mesmo adicionar outras variáveis que julgue importantes para afetar a taxa de câmbio.

A Testes de Raiz Unitária

Tabela 1: Estatísticas do Teste ADF

	tau3	phi2	phi3	tau2	phi1	tau1
cambio	−1.486	0.901	1.297	−1.493	1.170	−0.049
selic	−3.149	3.392	5.041	−2.566	3.337	−1.061
fed	−1.604	0.875	1.307	−1.243	0.778	−1.027
cds5y	−3.749	4.695	7.032	−3.254	5.304	−2.719

Tabela 2: Valores Críticos do Teste ADF

	1pct	5pct	10pct
tau3	−3.990	−3.430	−3.130
phi2	6.220	4.750	4.070
phi3	8.430	6.490	5.470
tau2	−3.460	−2.880	−2.570
phi1	6.520	4.630	3.810
tau1	−2.580	−1.950	−1.620

Tabela 3: Resultados do Protocolo de Pfaff (2008)

	Processo Gerador
cambio	Passeio Aleatório sem Drift
selic	Processo Estacionário
fed	Passeio Aleatório sem Drift
cds5y	Processo Estacionário

Referências

Bogdanski, J.; Tombini, A. A., and Werlang, S. R. Implementing Inflation Targeting in Brazil. *BCB Working Paper 01*, 2000.

Pfaff, B. *Analysis of integrated and cointegrated time series with R.* Springer, New York, second edition, 2008.