



Clube do Código 24

Como a Dívida Pública e a Incerteza Econômica  
se relacionam?

Vítor Wilher  
Mestre em Economia  
[analisemacro.com.br](http://analisemacro.com.br)

---

## Pacotes e Scripts Externos

```
library(forecast)
library(stargazer)
library(ggplot2)
library(ggthemr)
library(vars)
library(aod)

ggthemr('flat')
```

# 1 Introdução

Desde o início de 2014, a Dívida Bruta brasileira tem experimentado uma trajetória de rápida elevação, como pode ser visto no gráfico abaixo. Esse comportamento da dívida, de certo, refletia a enorme incerteza que havia sobre a economia brasileira, de forma geral e sobre o descontrole fiscal, em particular. A ideia é simples. Se o Estado passa a gastar mais do que arrecada, isso sinaliza descontrole fiscal que deve ser financiado por um aumento de dívida pública (ou por emissão monetária, mas isso...). Os agentes que carregam títulos públicos, claro, não são trouxas e pedem mais prêmio para fazer isso, expresso em mais juros. O processo amplifica o aumento inicial da dívida, porque o serviço dela passa a ser mais elevado. E tende a se tornar insustentável se assim for mantido. Simples, não? Bom, até pouco tempo nós não poderíamos quantificar esse aumento de incerteza e sua relação com a dívida pública. Hoje, isso é possível.

Como já abordei nesse espaço, o IBRE/FGV tem divulgado desde o final do ano passado um Índice de Incerteza Econômica que busca medir essa variável até então abstrata.<sup>1</sup> Uma vez que tenhamos esse índice, portanto, é possível verificar a sua relação com diversas variáveis, dentre elas a dívida bruta. Abaixo importamos os dados que utilizaremos.


```
data <- read.csv2('data.csv', header=T, sep=';', dec=',')
data$date <- as.Date(data$date, format='%d/%m/%Y')
```

E um gráfico da série de incerteza é posto abaixo.

```
ggplot(data, aes(date, iie))+
  geom_line(colour='red', size=.8)+
  xlab('')+ylab('Índice')+
  labs(title='Incerteza Econômica')
```


---

<sup>1</sup>Iniciativa para outros países pode ser vista em:<http://www.policyuncertainty.com/index.html>.



A já conhecida série da Dívida Bruta é posta logo abaixo.


```
ggplot(data, aes(date, dbgg))+
  geom_line(size=.8)+
  xlab('')+ylab('% PIB')+
  labs(title='Dívida Bruta')
```



A correlação entre as variáveis, por fim, pode ser vista abaixo.

```
ggplot(data, aes(dbgg, iie))+geom_point(col="firebrick", size=1)+
  geom_smooth(method='lm')+
  labs(title='Incerteza Econômica vs. Dívida Bruta')
```

```
xlab('Dívida Bruta')+ylab('Índice de Incerteza')
```



Como já esperado, existe uma forte correlação positiva entre as variáveis. Nessa edição do [Clube do Código](#) iremos aprofundar nosso entendimento sobre como essas duas variáveis se relacionam. Para isso, faremos uso de um Vetor de Correção de Erros (VEC), bem como utilizaremos o procedimento descrito em Toda and Yamamoto (1995) para ver se existe causalidade na relação.<sup>2</sup>

## 2 Cointegração e Vetor de Correção de Erros

Como pode ser visto no apêndice A, as séries não são estacionárias. Isso torna nosso trabalho de entendimento sobre como elas se relacionam um pouco mais complexo. Isto é, teremos que adotar algum procedimento alternativo para melhor verificar essa relação. Parece fazer sentido, a propósito, nos perguntar se a despeito das séries serem não estacionárias, existir uma tendência comum entre elas. Em termos um pouco mais formais, podemos investigar se existe uma relação de **cointegração** entre as séries. Observamos isso aplicando abaixo o teste de Johansen às mesmas, não sem antes transformá-las em séries temporais.<sup>3</sup>

---

<sup>2</sup>Esses procedimentos são necessários dado que, como ser visto no apêndice A, as séries não são estacionárias.

<sup>3</sup>Para uma referência sobre esse procedimento, ver Pfaff (2008).

```

### Transformar em série temporal
data <- ts(data[,-1], start=c(2006,12), freq=12)

### Selecionar Defasagem
def <- VARselect(data, lag.max=12, type="both")
def$selection

## AIC(n)  HQ(n)  SC(n) FPE(n)
##      2      1      1      2

### Teste de Cointegração
jo.eigen <- ca.jo(data, type='eigen', K=2, ecdet='const',
                  spec='transitory')
summary(jo.eigen)

##
## #####
## # Johansen-Procedure #
## #####
##
## Test type: maximal eigenvalue statistic (lambda max) , without linear trend and constant in coint
##
## Eigenvalues (lambda):
## [1] 1.895425e-01 1.417087e-02 3.848918e-18
##
## Values of teststatistic and critical values of test:
##
##          test 10pct  5pct  1pct
## r <= 1 |   1.70   7.52   9.24 12.97
## r = 0  |  25.01 13.75 15.67 20.20
##
## Eigenvectors, normalised to first column:
## (These are the cointegration relations)
##
##          dbgg.l1      iie.l1      constant
## dbgg.l1   1.0000000  1.0000000  1.0000000
## iie.l1    -0.7420122 -0.2969695 -0.0471781
## constant 20.5572999 -6.2420529 -52.2405820
##
## Weights W:
## (This is the loading matrix)

```

```
##
##          dbgg.l1      iie.l1      constant
## dbgg.d -0.02748846 0.002793553 -3.759008e-16
## iie.d   0.21092543 0.034855994  4.355178e-15
```

Pelo teste do máximo autovalor, não conseguimos rejeitar a hipótese nula de que existe ao menos um vetor de cointegração entre as variáveis. Podemos confirmar essa evidência agora com o teste do traço, abaixo.

```
jo.trace <- ca.jo(data, type='trace', K=2, ecdet='const',
                  spec='transitory')
summary(jo.trace)

##
## #####
## # Johansen-Procedure #
## #####
##
## Test type: trace statistic , without linear trend and constant in cointegration
##
## Eigenvalues (lambda):
## [1] 1.895425e-01 1.417087e-02 3.848918e-18
##
## Values of teststatistic and critical values of test:
##
##          test 10pct  5pct  1pct
## r <= 1 |   1.70   7.52   9.24 12.97
## r = 0  |  26.71 17.85 19.96 24.60
##
## Eigenvectors, normalised to first column:
## (These are the cointegration relations)
##
##          dbgg.l1      iie.l1      constant
## dbgg.l1  1.0000000  1.0000000  1.0000000
## iie.l1   -0.7420122 -0.2969695 -0.0471781
## constant 20.5572999 -6.2420529 -52.2405820
##
## Weights W:
## (This is the loading matrix)
##
```

```
##          dbgg.l1      iie.l1      constant
## dbgg.d -0.02748846 0.002793553 -3.759008e-16
## iie.d   0.21092543 0.034855994 4.355178e-15
```

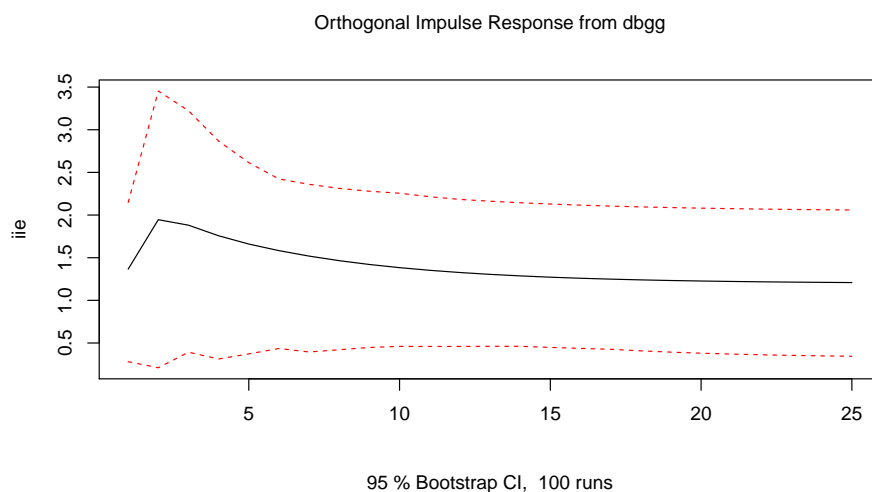
O teste do traço possui resultado semelhante. Isto é, podemos considerar que existe ao menos um vetor de cointegração entre as séries, algo bastante razoável, a propósito. Isso dito, montamos o VEC e transformamos o mesmo em um VAR conforme o código abaixo, para melhor analisar a relação entre as séries.

```
vec <- cajorls(jo.eigen, r=1)
vec.level <- vec2var(jo.eigen, r=1)
```

### 3 Funções Impulso-Resposta

Podemos agora verificar as funções de impulso-resposta. Primeiro, damos um impulso na Dívida Bruta e vemos a resposta no Índice de Incerteza.


```
irfiie <- irf(vec.level, impulse='dbgg', response='iie',
              boot = T, n.ahead=24, cumulative = F, ortho=T)
plot(irfiie)
```



Agora, fazemos o contrário.



```
irfdbgg <- irf(vec.level, impulse='iie', response='dbgg',
              boot = T, n.ahead=24, cumulative=F, ortho=T)
plot(irfdbgg)
```



Pela análise dessas funções, observamos que um impulso na Dívida Bruta tem efeitos estatisticamente significativos sobre a Incerteza Econômica.<sup>4</sup>

## 4 Decomposição de Variância

Uma outra forma de verificar o efeito de uma variável sobre a outra é ver a decomposição de variância, isto é, o quanto da variância de uma é explicada pela outra variável. Vemos isso com o código abaixo.

```
fevd(vec.level, n.ahead=12)

## $dbgg
##           dbgg           iie
## [1,] 1.0000000 0.0000000000
## [2,] 0.9993560 0.0006440298
## [3,] 0.9917763 0.0082237006
## [4,] 0.9662556 0.0337443767
## [5,] 0.9305808 0.0694192350
```

<sup>4</sup>Como as séries não são estacionárias, o choque tem efeito permanente, *ceteris paribus*.

```
## [6,] 0.8918531 0.1081468985
## [7,] 0.8540640 0.1459360493
## [8,] 0.8191042 0.1808958298
## [9,] 0.7876618 0.2123381949
## [10,] 0.7597984 0.2402016300
## [11,] 0.7352832 0.2647168189
## [12,] 0.7137725 0.2862275483
##
## $iie
##          dbgg          iie
## [1,] 0.04264400 0.9573560
## [2,] 0.07128420 0.9287158
## [3,] 0.08759612 0.9124039
## [4,] 0.09843005 0.9015700
## [5,] 0.10695286 0.8930471
## [6,] 0.11430464 0.8856954
## [7,] 0.12093549 0.8790645
## [8,] 0.12706350 0.8729365
## [9,] 0.13281177 0.8671882
## [10,] 0.13825670 0.8617433
## [11,] 0.14344926 0.8565507
## [12,] 0.14842551 0.8515745
```

Nessa forma de ver, observamos que uma parte crescente da variância da Dívida Bruta é explicada pela Incerteza Econômica. No caso contrário, menos da variância da Incerteza Econômica é explicada pela Dívida Bruta.

## 5 Teste De Causalidade

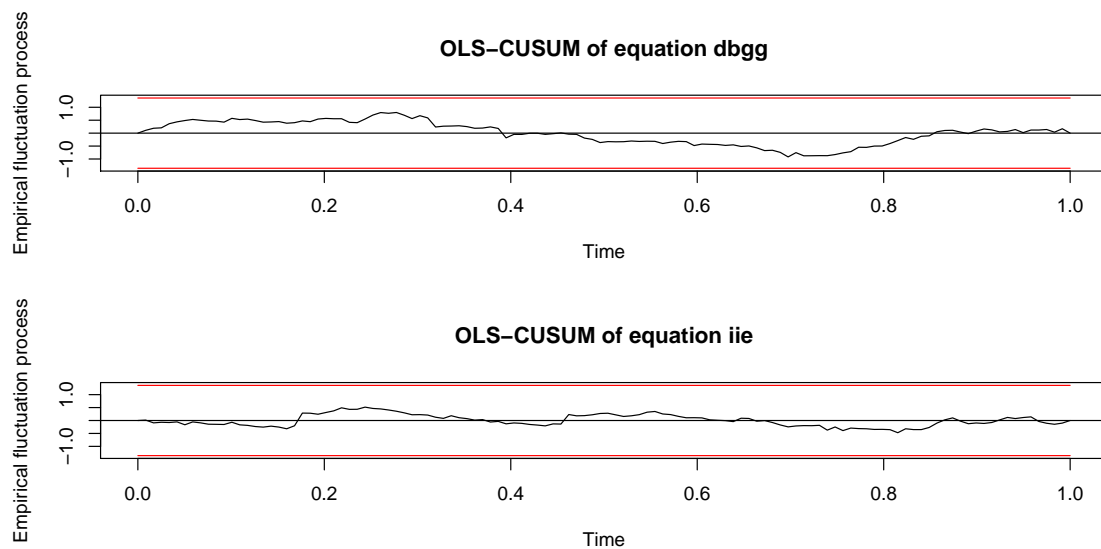
Por fim, aplicamos o procedimento descrito em Toda and Yamamoto (1995) para verificar causalidade na relação entre Dívida Bruta e Incerteza Econômica. No código abaixo, montamos o VAR e verificamos a autocorrelação serial e a estabilidade do mesmo.

```
### Montar o VAR
### VAR(2)
var2 <- VAR(data, p=2, type='both')
serial.test(var2)
```

```
##
## Portmanteau Test (asymptotic)
##
## data: Residuals of VAR object var2
## Chi-squared = 40.03, df = 56, p-value = 0.9471
```

Não conseguimos rejeitar a hipótese nula de ausência de autocorrelação.

```
plot(stability(var2))
```



E abaixo fazemos o teste de Wald, para ver o efeito conjunto de uma variável sobre a outra.

```
### Teste de Wald
var3 <- VAR(data, p=3, type='both')
### Wald Test 01: IIE não granger causa DBGG
wald.test(b=coef(var3$varresult[[1]]),
          Sigma=vcov(var3$varresult[[1]]),
          Terms=c(2,4))

## Wald test:
## -----
##
## Chi-squared test:
## X2 = 2.3, df = 2, P(> X2) = 0.31

### Wald Test 02: DBGG não granger causa IIE
wald.test(b=coef(var3$varresult[[2]]),
          Sigma=vcov(var3$varresult[[2]]),
```

```
Terms= c(1,3))  
  
## Wald test:  
## -----  
##  
## Chi-squared test:  
## X2 = 1.0, df = 2, P(> X2) = 0.6
```

O teste de Wald nos informa que não conseguimos rejeitar o efeito da dívida sobre a incerteza ou dessa em relação aquela. Isto é, temos uma causalidade bidirecional nesse caso.

## 6 Discussão Final

Dívida Bruta e Incerteza Econômica parecem estar relacionadas no tempo. Um choque na dívida parece ter efeitos sobre a incerteza, enquanto cerca de um terço da variância da dívida é explicada pela incerteza. Por fim, há causalidade bidirecional na relação entre as duas variáveis.

## A Testes de Raiz Unitária

Tabela 1: Estatísticas do Teste ADF

	tau3	phi2	phi3	tau2	phi1	tau1
dbgg	0.052	2.232	2.439	0.705	1.132	1.385
iie	-2.995	3.169	4.521	-2.292	2.855	0.362

Tabela 2: Valores Críticos do Teste ADF

	1pct	5pct	10pct
tau3	-3.990	-3.430	-3.130
phi2	6.220	4.750	4.070
phi3	8.430	6.490	5.470
tau2	-3.460	-2.880	-2.570
phi1	6.520	4.630	3.810
tau1	-2.580	-1.950	-1.620

Tabela 3: Resultados do Protocolo de Pfaff (2008)

	Processo Gerador
dbgg	Passeio Aleatório sem Drift
iie	Passeio Aleatório sem Drift

## Referências

Pfaff, B. *Analysis of integrated and cointegrated time series with R*. Springer, New York, second edition, 2008.

Toda, H. Y. and Yamamoto, T. Statistical inference in vector autoregressions with possibly integrated process. *Journal of Econometrics*, 66:225–250, 1995.